

Carolina da Silva Ezequiel
Email: carolezeq15@gmail.com

Sistema Inteligente para Detecção de Conversão de Vegetação em Pastagem Utilizando
Sensoriamento Remoto e Aprendizado de Máquina

Três Lagoas | MS

Orientadora: Prof.^a Aline Lopes
Email: aline.llopes@unicesumar.edu.br
Instituição de Vínculo: Universidade Cesumar - UNICESUMAR
Av. Guedner, nº 1610 – Jardim Aclimação
Maringá – PR
(44) 3027-6360

Resumo

O avanço das atividades agropecuárias tem promovido transformações significativas na cobertura vegetal, tornando essencial o desenvolvimento de ferramentas capazes de monitorar e prever mudanças no uso da terra para subsidiar ações de gestão ambiental e planejamento territorial. Neste contexto, este trabalho apresenta o desenvolvimento de um sistema inteligente para detecção e análise da conversão de áreas de vegetação em pastagem no município de Três Lagoas (MS), utilizando dados de sensoriamento remoto e técnicas de aprendizado de máquina. A metodologia integra séries temporais do índice de vegetação (NDVI) derivadas de imagens MODIS com o algoritmo Random Forest, permitindo a classificação do uso e cobertura do solo e a identificação de mudanças ocorridas entre 2018 e 2024. Além da detecção das transformações na paisagem, o sistema realiza a quantificação das áreas convertidas e avalia padrões espaciais associados à expansão das pastagens, contribuindo para uma compreensão mais abrangente da dinâmica de ocupação territorial. Como diferencial, a plataforma incorpora uma análise de risco ambiental baseada na distribuição espacial das áreas convertidas e desenvolve projeções de cenários futuros até 2030, alinhadas aos compromissos globais de sustentabilidade e mitigação das mudanças climáticas, incluindo as metas estabelecidas pelo Acordo de Paris. Os resultados são disponibilizados por meio de um mapa interativo e de indicadores geoespaciais que facilitam a visualização das áreas críticas, das tendências de expansão e dos potenciais impactos ambientais decorrentes da conversão da vegetação. Dessa forma, o trabalho contribui para o monitoramento ambiental em escala municipal, fornecendo uma ferramenta de apoio à tomada de decisão para gestores públicos, pesquisadores e demais atores envolvidos na conservação dos recursos naturais, além de evidenciar o potencial da inteligência artificial como instrumento estratégico para a promoção do desenvolvimento sustentável.

Introdução

O Cerrado brasileiro é o segundo maior bioma da América do Sul e uma das regiões mais biodiversas do planeta, desempenhando papel fundamental na conservação da biodiversidade, na regulação climática e na manutenção dos recursos hídricos (Alencar et al., 2020). Apesar de sua relevância ecológica, o bioma vem sofrendo intensas transformações decorrentes da expansão das atividades agropecuárias, especialmente pela conversão de áreas de vegetação nativa em pastagens e áreas agrícolas. Esse processo tem contribuído para a fragmentação de habitats, redução da biodiversidade, degradação dos solos e aumento das emissões de gases de efeito estufa, comprometendo serviços ecossistêmicos essenciais para a sustentabilidade ambiental e econômica da região (IPCC, 2019; MapBiomas, 2026).

Diante desse cenário, o monitoramento das mudanças no uso e cobertura do solo torna-se ferramenta indispensável para subsidiar ações de conservação ambiental, planejamento territorial e gestão sustentável dos recursos naturais (Souza et al., 2020). Entretanto, a grande extensão territorial do Cerrado e a velocidade com que ocorrem as

transformações na paisagem dificultam a realização de análises contínuas por métodos convencionais de campo, demandando o desenvolvimento de abordagens automatizadas, escaláveis e capazes de processar grandes volumes de dados em diferentes escalas espaciais e temporais (Gorelick et al., 2017).

O avanço das geotecnologias tem possibilitado importantes progressos nesse sentido. A integração entre sensoriamento remoto e técnicas de aprendizado de máquina tem se destacado como uma abordagem eficiente para detectar, monitorar e prever mudanças na cobertura vegetal. Imagens de satélite associadas a algoritmos de inteligência artificial vêm sendo amplamente utilizadas para avaliar a degradação e a dinâmica de pastagens em diferentes regiões do mundo. Estudos recentes demonstram que dados de sensoriamento remoto de alta resolução combinados com modelos de aprendizado de máquina podem fornecer informações precisas sobre biomassa, qualidade da vegetação e padrões de degradação, embora ainda existam desafios relacionados à resolução espacial e à interferência de fatores atmosféricos, como a cobertura de nuvens (Ogungbuyi et al., 2023).

Na Colômbia, por exemplo, o uso de imagens multiespectrais associado a algoritmos como Random Forest e Redes Neurais Regularizadas Bayesianas apresentou resultados promissores na previsão da qualidade nutricional e da biomassa de pastagens tropicais (Zwick et al., 2024). De forma semelhante, pesquisas realizadas na Bulgária demonstraram elevada precisão na classificação de áreas degradadas utilizando modelos de aprendizado de máquina, como Random Forest e Máquinas de Vetores de Suporte (Evstatiev et al., 2024). Já estudos conduzidos após o desastre nuclear de Fukushima evidenciaram a importância da utilização integrada de imagens de média e alta resolução para compreender a dinâmica espaço-temporal das pastagens, destacando a capacidade dos sensores orbitais em detectar alterações na paisagem ao longo do tempo (Muxiye & Yonezawa, 2023). Mais recentemente, modelos de aprendizado profundo aplicados a séries temporais do satélite Sentinel-2 demonstraram elevado potencial para identificar padrões sazonais de pastejo e otimizar processos de monitoramento territorial (Aleksis et al., 2025).

Nesse contexto, o sensoriamento remoto aliado a técnicas de aprendizado de máquina surge como uma ferramenta promissora para a detecção e análise dessas mudanças na superfície terrestre (Jensen, 2011). Índices de vegetação, como o NDVI (*Normalized Difference Vegetation Index*), permitem avaliar a dinâmica da cobertura vegetal ao longo do tempo (Rouse et al., 1974), enquanto algoritmos de classificação supervisionada, como o *Random Forest*, possibilitam a identificação de padrões espaciais e temporais com maior robustez e precisão (Breiman, 2001).

Apesar dos avanços observados na literatura internacional, ainda são escassos os estudos que integram séries temporais de índices de vegetação, algoritmos de aprendizado de máquina e modelagem preditiva para avaliar a conversão de vegetação nativa em pastagens no Cerrado brasileiro em escala municipal. Nesse sentido, o município de Três Lagoas (MS) constitui uma área de interesse estratégico devido à intensa expansão das atividades agropecuárias observada nas últimas décadas, tornando-se um cenário adequado para a aplicação de ferramentas inovadoras de monitoramento ambiental.

Assim, o presente trabalho tem como objetivo o desenvolvimento de um sistema inteligente para detectar a conversão de vegetação em pastagem no município de Três Lagoas (MS), integrando dados de satélite, aprendizado de máquina e análise espacial. Além da

identificação das mudanças ocorridas entre 2018 e 2024, o sistema também busca avaliar a distribuição espacial das áreas convertidas, identificar zonas de risco ambiental e projetar cenários futuros de expansão até o ano de 2030, contribuindo para o planejamento territorial, a gestão ambiental e a promoção do desenvolvimento sustentável.

Objetivo Geral

Desenvolver um sistema inteligente para detectar e analisar a conversão de áreas de vegetação em pastagem no município de Três Lagoas (MS), utilizando dados de sensoriamento remoto e técnicas de aprendizado de máquina, visando a projeção de cenários de risco ambiental até o ano de 2030.

Objetivos Específicos:

- Identificar e mapear áreas de convertidas de vegetação para pastagem entre os anos de 2018 e 2024;
- Aplicar o índice de Vegetação por Diferença Normalizada (NDVI) para analisar a dinâmica espaço-temporal da cobertura vegetal;
- Utilizar o algoritmo Random Forest para classificação do uso e cobertura do solo;
- Avaliar a distribuição espacial das áreas convertidas em relação a elementos ambientais relevantes, especialmente a rede hidrográfica;
- Estimar a expansão futura das áreas de pastagem por meio de modelagem preditiva, com projeção até 2030
- Identificar e mapear áreas de maior risco ambiental associadas à conversão da vegetação nativa;
- Desenvolver mapas interativos que auxiliem na visualização das áreas críticas e forneçam suporte à tomada de decisão para o planejamento e a gestão ambiental.

Metodologia

Área de Estudo

O estudo foi realizado no município de Três Lagoas, localizado no estado de Mato Grosso do Sul (Figura 1), inserido no bioma Cerrado (IBGE, 2019). A região apresenta forte presença de atividades agropecuárias, especialmente a expansão de áreas de pastagem, o que a torna um local estratégico para análise de mudanças no uso e cobertura do solo (SEMAGRO, 2020).

Além disso, a área possui significativa rede hidrográfica, com destaque para a bacia do Rio Paraná, fator relevante para a análise de risco ambiental, considerando a relação entre mudanças no uso do solo e impactos sobre os recursos hídricos (ANA, 2020).




Figura 1. Localização da área de estudo no município de Três Lagoas, estado de Mato Grosso do Sul, Brasil.

Dados Utilizados

Foram utilizados dados de sensoriamento remoto provenientes do sensor *Moderate Resolution Imaging Spectroradiometer* (MODIS), especificamente o produto MOD13Q1 (Versão 6.1), que possui resolução espacial de 250 metros e resolução temporal de 16 dias, abrangendo os anos de 2018 e 2024 (DIDAN, 2021).

O índice de vegetação por Diferença Normalizada - NDVI foi utilizado como principal variável para análise da cobertura vegetal, devido à sua capacidade de representar a densidade e vigor da vegetação.

Também foram utilizados dados de uso e cobertura da terra do Projeto MapBiomas Coleção 9, empregados como referência para treinamento e validação das classificações (MAPBIOMAS, 2024). Imagens de alta resolução (10 metros) dos satélites Sentinel-2 (constelação MSI), disponíveis na plataforma *Google Earth Engine* (GEE), foram utilizadas para inspeção visual e conferência das amostras coletadas (GORELICK *et al.*, 2017).

Pré-processamento dos Dados

Os dados MODIS foram obtidos por meio da plataforma NASA EarthData, utilizando a biblioteca Earthaccess em ambiente Python (AUSTIN *et al.*, 2023).

Os arquivos no formato *Hierarchical Data Format* (HDF) foram processados para extração da banda NDVI, sendo posteriormente recortados para os limites do município de Três Lagoas (IBGE, 2019).

Durante esse processo, pixels corrompidos por cobertura de nuvens, sombras ou falhas instrumentais foram severamente mascarados e removidos por meio das camadas de controle de qualidade (*Pixel Reliability* e *QA Science Quality*) disponibilizadas nativamente no produto MOD13Q1 (DIDAN, 2021). Para minimizar interferências atmosféricas e ruídos temporais, foi calculada a mediana anual dos valores de NDVI para cada ano analisado. Esse procedimento permitiu gerar imagens representativas da condição média da vegetação em cada período estudado (SOUZA *et al.*, 2020).

Extração de Variáveis

O NDVI foi utilizado como principal indicador da dinâmica da vegetação. Além dos valores medianos anuais absolutos de NDVI de cada período, geraram-se variáveis métricas derivadas baseadas em álgebra de mapas. A principal delas foi a diferença temporal absoluta (ΔNDVI), calculada pela subtração direta entre os anos avaliados $\Delta\text{NDVI}_{2024} - \Delta\text{NDVI}_{2018}$. Essa métrica espectral permitiu isolar espacialmente e identificar com precisão as áreas que sofreram redução abrupta ou aumento linear da cobertura vegetal ao longo do recorte temporal adotado (JENSEN, 2011).

Coleta de Amostras

A coleta de amostras foi realizada de forma supervisionada dentro da plataforma de computação em nuvem *Google Earth Engine* (GORELICK *et al.*, 2017). Utilizando os mosaicos do Sentinel-2 livres de nuvens, as amostras de pixels foram distribuídas aleatoriamente por amostragem estratificada entre as classes de "Vegetação" e "Pastagem", buscando assegurar a representatividade espacial e espectral em toda a extensão territorial do município.

A interpretação visual e espectral dos alvos foi complementada de forma síncrona com os mapas de transição do MapBiomas Coleção 9, elevando a confiabilidade do conjunto de dados (MAPBIOMAS, 2024). Posteriormente, a totalidade do banco de amostras foi dividida aleatoriamente em duas frações independentes: 70% dos dados foram destinados ao conjunto de treinamento do classificador e os 30% restantes foram reservados estritamente para a etapa de validação (CONGALTON; GREEN, 2019).




Figura 2. Distribuição espacial dos pontos amostrais utilizados para treinamento e validação do modelo Random Forest no município de Três Lagoas (MS). Os pontos foram classificados

em duas categorias: vegetação e pastagem, servindo como base para a construção do modelo de classificação do uso e cobertura do solo.

Classificação do Uso e Cobertura do Solo

Para a classificação do uso e cobertura do solo, foi utilizado o algoritmo Random Forest, amplamente empregado em estudos ambientais devido à sua elevada capacidade de classificação e resistência ao sobreajuste (*overfitting*) (BREIMAN, 2001). As variáveis predictoras de entrada consistiram nos valores pixel a pixel de NDVI e nas métricas de variação temporal (Δ NDVI).

O estimador foi parametrizado com um total de 200 árvores de decisão independentes ($n_estimators = 200$), valor definido após testes preliminares de convergência. Após a etapa de treinamento e execução do modelo, foram exportados os mapas temáticos raster finais de uso e cobertura do solo calibrados para os anos de 2018 e 2024.

Avaliação de Desempenho

A validação exaustiva do classificador foi conduzida por meio de métricas estatísticas derivadas da Matriz de Confusão, calculadas a partir do conjunto de teste de 30% mantido independente (CONGALTON; GREEN, 2019). Determinaram-se a Acurácia Global, o Coeficiente Kappa de Cohen, a Precisão (proporção de acertos positivos), a Revocação (*Recall* - sensibilidade do modelo) e o escore F_1 (*F1-Score*), que computa a média harmônica balanceada entre precisão e revocação (SOKOLOVA; LAPALME, 2009). Os resultados foram adicionalmente confrontados por validação cruzada espacial direta com as estatísticas de área publicadas pelo MapBiomas (MAPBIOMAS, 2024).

Deteção de Mudanças

A análise de detecção de mudanças (*Change Detection*) foi conduzida por meio da comparação entre os mapas classificados dos anos de 2018 e 2024.

Foram identificadas áreas de conversão de vegetação para pastagem, bem como áreas de regeneração, permitindo quantificar as transformações ocorridas no período analisado. Essa abordagem possibilitou compreender a dinâmica temporal do uso do solo e identificar regiões com maior intensidade de alteração (JENSEN, 2011).




Figura 3. Distribuição espacial do NDVI no município de Três Lagoas (MS) durante o período seco. (A) NDVI referente ao ano de 2018; (B) NDVI referente ao ano de 2024; e (C) Δ NDVI, representando a diferença entre os dois períodos. Valores positivos indicam

aumento da cobertura vegetal, enquanto valores negativos indicam redução do vigor ou da densidade da vegetação, podendo estar associados a processos de conversão do uso do solo.

Modelagem Preditiva

A projeção de cenários futuros de cobertura da terra foi estruturada a partir das taxas e intensidades históricas de conversão observadas no intervalo de 2018 a 2024. Adotando modelos baseados em Cadeias de Markov e Autômatos Celulares (CA-Markov), as tendências de transição de matrizes espaciais foram extrapoladas probabilisticamente para estimar cenários potenciais de expansão da fronteira pastoril até o ano de 2030 (EASTMAN, 2016). Os cenários gerados possuem caráter exploratório e preditivo sob a premissa de continuidade do padrão socioeconômico atual (*business-as-usual*), servindo de ferramenta indicativa para o ordenamento territorial municipal.

Análise de Risco Ambiental

A modelagem de risco ambiental foi estruturada a partir da integração espacial de critérios múltiplos em um ambiente de Sistema de Informação Geográfica (SIG). Foram modelados três fatores condicionantes essenciais: a densidade de conversão da vegetação nativa calculada neste estudo, a distância euclidiana em relação à rede hidrográfica mapeada (ANA, 2020) e a declividade do terreno expressa em graus, obtida a partir do Modelo Digital de Elevação (MDE) do projeto *Topodata* / SRTM (VALERIANO, 2008).

Essas variáveis foram ponderadas e normalizadas para a formulação do Índice de Risco Ambiental (IRA). As áreas do município foram fatiadas e hierarquizadas em três níveis de criticidade ambiental: baixo, médio e alto. A proximidade geográfica com os corpos hídricos foi parametrizada com peso prioritário, haja vista que a remoção da vegetação ripária e de preservação permanente deflagra processos erosivos acelerados, assoreamento de leitos e perda drástica da qualidade da água doce (Formulas adaptadas de EASTMAN, 2016).

Zoneamento Ambiental

A partir do Índice de Risco Ambiental, foi elaborado um zoneamento socioambiental para Três Lagoas (MS). O território municipal foi compartimentado em três macrozonas diretrizes: Áreas Adequadas à Expansão Agropecuária Otimizada, Áreas com Restrições Ambientais Severas e Áreas Críticas para a Conservação e Restauração Ecológica. Este arcabouço cartográfico atua diretamente como subsídio técnico focado no Planejamento Sistemático da Paisagem e na tomada de decisão normativa por órgãos ambientais locais (SANTOS, 2004).

Visualização dos Resultados

Para garantir a reprodutibilidade, transparência e democratização do acesso aos dados científicos, todos os resultados geoespaciais foram exportados e integrados a uma plataforma interativa baseada em ambiente *WebGIS*. O sistema foi codificado em linguagem Python através da biblioteca de mapeamento interativo Folium (FILHO, 2021). A aplicação estruturada em formato de painel geográfico permite a visualização dinâmica das camadas de

transição, sobreposição dos cenários simulados para 2030, consulta espacial aos níveis do IRA e vetorização das áreas críticas por qualquer tomador de decisão conectado à rede.

Plataforma Interativa de Visualização

Os resultados obtidos foram disponibilizados em uma plataforma de visualização interativa desenvolvida com a biblioteca Folium e hospedada por meio do serviço GitHub Pages. A plataforma pode ser acessada publicamente pelo endereço:

https://carolezeq-analist.github.io/projeto.cnpq_2026/

A aplicação permite a exploração espacial dos resultados gerados pelo estudo, incluindo os mapas de classificação do uso e cobertura do solo, as áreas de conversão de vegetação para pastagem, os níveis do Índice de Risco Ambiental (IRA) e os cenários projetados de expansão até o ano de 2030.

Uma das principais vantagens da plataforma é a possibilidade de acesso às informações sem a necessidade de softwares de geoprocessamento especializados, tornando os resultados mais acessíveis a gestores públicos, técnicos municipais, pesquisadores e demais tomadores de decisão envolvidos no planejamento territorial e na gestão ambiental.

Além disso, visando garantir a transparência e a reprodutibilidade da metodologia, todo o código-fonte desenvolvido para o projeto foi disponibilizado em repositório público no GitHub:

https://github.com/carolezeq-Analist/projeto.cnpq_2026

A disponibilização dos scripts e procedimentos empregados permite que a metodologia seja adaptada e aplicada em outros municípios ou regiões, ampliando seu potencial de utilização em iniciativas de monitoramento ambiental e apoio à tomada de decisão.

Resultados

Os resultados obtidos demonstram que o algoritmo Random Forest apresentou elevado desempenho na classificação das classes de vegetação nativa e pastagem, permitindo identificar mudanças no uso do solo entre 2018 e 2024 e gerar subsídios para a análise de risco ambiental.

Desempenho do Modelo de Classificação

Foram utilizados 254 pontos válidos para treinamento e validação do modelo Random Forest, sendo 150 pontos representativos da classe vegetação nativa e 104 pontos da classe pastagem. O algoritmo foi configurado com 200 árvores de decisão e aplicado aos dados derivados do produto MOD13Q1 do sensor MODIS.

A matriz de confusão obtida para o algoritmo Random Forest (Figura 4) demonstrou elevado desempenho na classificação das classes vegetação nativa e pastagem. Do total de 77 amostras avaliadas, 70 foram classificadas corretamente, resultando em uma acurácia global de 90,91%. O modelo classificou corretamente 41 amostras de vegetação nativa e 29 amostras de pastagem, enquanto apenas quatro amostras de vegetação foram incorretamente classificadas como pastagem e três amostras de pastagem foram classificadas como vegetação.

Os indicadores de desempenho confirmam a elevada confiabilidade do modelo. A classe vegetação apresentou precisão de 93,18%, recall de 91,11% e F1-score de 92,13%. Para a classe pastagem, foram obtidos valores de precisão de 87,88%, recall de 90,63% e F1-score de 89,23%. Considerando ambas as classes, o F1-score médio foi de aproximadamente 90,8%, evidenciando equilíbrio entre precisão e capacidade de detecção das classes analisadas.

Esses resultados indicam que o algoritmo Random Forest foi eficiente na discriminação entre vegetação nativa e pastagem, apresentando baixos índices de erro e elevada capacidade de generalização. Dessa forma, o modelo mostrou-se adequado para aplicações de monitoramento ambiental e análise de mudanças no uso e cobertura do solo na área de estudo.

A validação cruzada (5-fold cross-validation) apresentou acurácia média de $0,9055 \pm 0,0261$, indicando estabilidade e boa capacidade de generalização do modelo.




Figura 4. Matriz de confusão do modelo Random Forest utilizada para avaliar a classificação das classes vegetação nativa e pastagem. Os valores da diagonal principal representam as classificações corretas, enquanto os demais representam erros de classificação.

Importância das Variáveis

A análise da importância das variáveis no modelo Random Forest (Figura 5) demonstrou que o NDVI de 2018 foi o atributo mais relevante para a classificação das classes de uso e cobertura do solo, apresentando importância relativa de aproximadamente 62,5%. Em seguida, o Δ NDVI (diferença entre os períodos analisados) contribuiu com cerca de 25,0%, enquanto o NDVI de 2024 apresentou menor influência no modelo, com aproximadamente 12,5% de importância relativa.

A predominância do NDVI de 2018 sugere que as condições iniciais da cobertura vegetal exerceram forte influência na diferenciação entre vegetação nativa e pastagem. Por outro lado, a contribuição do Δ NDVI demonstra que as alterações temporais da vegetação foram importantes para a identificação das áreas submetidas a mudanças de uso do solo ao longo do período analisado.

Esses resultados evidenciam que tanto as características estruturais da vegetação quanto sua dinâmica temporal foram fundamentais para o desempenho do modelo de classificação.




Figura 5. Importância relativa das variáveis utilizadas no modelo Random Forest. O gráfico apresenta a contribuição de cada variável para o processo de classificação das classes de uso e cobertura do solo.

Classificação do Uso e Cobertura do Solo

Os mapas de classificação gerados para os anos de 2018 e 2024 (Figura 6) mostram a distribuição espacial das classes vegetação nativa e pastagem na área de estudo.

Visualmente, observa-se predominância da classe vegetação em ambos os períodos, embora seja possível identificar alterações pontuais na distribuição espacial das pastagens ao longo do tempo. Essas mudanças refletem a dinâmica de ocupação territorial observada no município de Três Lagoas, caracterizada pela expansão gradual das atividades agropecuárias.




Figura 6. Mapas de classificação do uso e cobertura do solo para os anos de 2018 e 2024 obtidos por meio do algoritmo Random Forest. A cor verde representa áreas de vegetação nativa e a cor laranja representa áreas de pastagem.

Deteção de Mudanças no Uso do Solo

A comparação entre os mapas classificados permitiu identificar as mudanças ocorridas entre 2018 e 2024 (Figura 7).

As áreas destacadas em vermelho representam conversões de vegetação nativa para pastagem, enquanto as áreas em verde indicam possíveis processos de regeneração ou

transição de pastagem para vegetação. As áreas em branco correspondem às regiões que permaneceram sem alteração durante o período analisado.

Os resultados evidenciam que as mudanças ocorreram de forma distribuída pela paisagem, indicando uma dinâmica contínua de transformação da cobertura do solo. A presença de áreas convertidas sugere a expansão das atividades produtivas, enquanto as áreas de regeneração podem estar associadas a processos de recuperação natural ou mudanças no manejo da terra.




Figura 7. Mapa de mudanças do uso e cobertura do solo entre 2018 e 2024. As áreas em vermelho indicam conversão de vegetação para pastagem, as áreas em verde representam transições de pastagem para vegetação e as áreas em branco correspondem à ausência de mudança.

Distribuição da Rede Hidrográfica e Proximidade da Água

A Figura 8 apresenta a rede hidrográfica identificada na área de estudo e o mapa de proximidade dos corpos hídricos.

Observa-se que a rede hidrográfica está concentrada em determinados setores da área analisada, formando corredores ambientais importantes para a manutenção da biodiversidade e dos processos ecológicos. O mapa de proximidade evidencia um gradiente espacial no qual os valores mais elevados indicam maior proximidade dos recursos hídricos.

Essa variável foi utilizada na construção do Índice de Risco Ambiental, considerando que a remoção da vegetação em áreas próximas aos corpos d'água pode intensificar processos de erosão, assoreamento e degradação da qualidade da água.




Figura 8. Rede hidrográfica utilizada na análise ambiental (esquerda) e mapa de proximidade dos corpos hídricos (direita). Os tons mais escuros representam áreas mais próximas dos recursos hídricos e, conseqüentemente, potencialmente mais sensíveis às alterações no uso do solo.

Conversão de Vegetação para Pastagem

A comparação dos mapas classificados de 2018 e 2024 permitiu identificar as alterações ocorridas na cobertura do solo ao longo dos seis anos analisados no município de Três Lagoas, Mato Grosso do Sul.

Os resultados indicaram uma conversão de aproximadamente **12.368,75 hectares de vegetação para pastagem**, evidenciando a continuidade da pressão antrópica sobre áreas naturais do Cerrado. Esse processo está associado principalmente à expansão das atividades agropecuárias, uma das principais causas de transformação da paisagem no bioma.

Por outro lado, foram identificados **12.868,75 hectares de áreas em regeneração**, caracterizadas pela transição de áreas anteriormente classificadas como pastagem para vegetação. Esse valor ligeiramente superior à área convertida sugere a ocorrência simultânea de processos de recuperação da cobertura vegetal, possivelmente relacionados ao abandono de áreas produtivas, regeneração natural ou práticas de restauração.

De maneira geral, os resultados indicam uma dinâmica espacial complexa, marcada tanto pela expansão quanto pela recuperação da vegetação, evidenciando a constante transformação da paisagem no período analisado.

Índice de Risco Ambiental (IRA)

A integração das informações de mudança do uso do solo, proximidade da rede hidrográfica e declividade do terreno permitiu a construção do Índice de Risco Ambiental (IRA) (Figura 9).

As áreas classificadas como de **baixo risco ambiental** totalizaram **15.762,50 hectares**, correspondendo a regiões onde os impactos potenciais decorrentes da conversão da vegetação são considerados reduzidos.

As áreas de **risco médio** representaram a maior parcela da área analisada, totalizando **36.787,50 hectares**. Essas regiões apresentam características intermediárias de vulnerabilidade ambiental e demandam monitoramento contínuo para evitar processos de degradação.

Já as áreas classificadas como de **alto risco ambiental** somaram **9.950,00 hectares**, concentrando-se principalmente em locais próximos à rede hidrográfica e em áreas mais suscetíveis a processos erosivos. Nessas regiões, a conversão da vegetação pode gerar impactos mais severos sobre os recursos naturais, especialmente sobre a qualidade da água e a estabilidade dos solos.

Considerando a área total analisada pelo modelo, aproximadamente 16% do território foi enquadrado na categoria de alto risco ambiental. Esse percentual evidencia a existência de áreas prioritárias para monitoramento e implementação de medidas de conservação, especialmente em regiões onde a conversão recente da vegetação coincide com fatores naturais de vulnerabilidade ambiental.

Os resultados demonstram que aproximadamente 16% da área analisada apresenta elevado potencial de vulnerabilidade ambiental, reforçando a necessidade de medidas de conservação e manejo sustentável.

A modelagem espacial do Índice de Risco Ambiental (IRA) gerou dois produtos cartográficos complementares, conforme detalhado na **Figura X**. O primeiro mapa (Figura 9 A) exibe o **IRA Contínuo**, cuja variação numérica de 0,0 a 1,0 indica que, quanto mais próxima de 1,0 (tonalidades de vermelho escuro), maior é a vulnerabilidade e o risco socioambiental da área. Observa-se uma variação espacial pixel a pixel com núcleos de criticidade acentuada (vermelho intenso) distribuídos de forma fragmentada, mas com maior densidade na porção superior esquerda e na faixa inferior direita da imagem, refletindo a sobreposição de fatores como a alta taxa de conversão recente e a proximidade de corpos d'água.

O segundo mapa (Figura 9B) apresenta o **IRA Classificado**, que atua diretamente como o zoneamento de risco do território ao fatiar o índice contínuo em três intervalos normativos de criticidade. A classe de **Baixo Risco (0–0,33)**, representada na cor verde, delimita zonas de maior estabilidade ambiental ou menor pressão antrópica direta. O **Médio Risco (0,33–0,67)**, mapeado em laranja, predomina na paisagem e forma grandes blocos homogêneos que cobrem a maior parte da área de estudo, caracterizando zonas de atenção moderada devido à dinâmica de uso. Por fim, a classe de **Alto Risco (0,67–1,0)**, representada pelos pontos em vermelho, aparece dispersa de forma granular sobreposta às áreas de médio e baixo risco, mapeando com precisão os setores prioritários que demandam ações imediatas de monitoramento, fiscalização e recuperação ecológica.




Figura 9. Resultados da análise espacial de risco ambiental para o município de Três Lagoas (MS). (A) Índice de Risco Ambiental (IRA), obtido pela combinação ponderada de fatores de vulnerabilidade ambiental associados à conversão da vegetação nativa. (B) Zoneamento

ambiental resultante da classificação do IRA, identificando áreas adequadas ao uso produtivo, áreas sujeitas a restrições ambientais e áreas críticas para conservação. Essas informações fornecem subsídios para o planejamento territorial e a tomada de decisão voltada à gestão sustentável do uso do solo.

O produto cartográfico final do ordenamento territorial é apresentado na **Figura 10**, que ilustra o **Zoneamento de Risco Ambiental** proposto para o município de Três Lagoas (MS), inserido no bioma Cerrado. A espacialização das macrozonas diretrizes revela uma paisagem fragmentada com clara delimitação de aptidões e restrições socioambientais.

A classe mapeada em verde, correspondente às áreas **Adequadas à Expansão Sustentável**, distribui-se de forma contínua em uma faixa diagonal que cruza a região central e se estende até a porção superior direita da área de estudo. Essas superfícies representam setores com maior estabilidade biofísica e menor vulnerabilidade, sendo tecnicamente indicadas para a consolidação e otimização das atividades agropecuárias existentes, desde que aliadas a boas práticas de manejo do solo.

Em contrapartida, as áreas classificadas **Com Restrições Ambientais** (representadas na cor laranja) dominam quantitativamente o território, consolidando dois grandes blocos homogêneos nas porções noroeste e sudeste da paisagem. Esse predomínio evidencia que a maior parte do município possui restrições moderadas ao uso antrópico intensivo, exigindo dos produtores e gestores um planejamento rigoroso para evitar processos de degradação do solo.

Por fim, a categoria de áreas **Críticas — Prioridade Conservação** é representada por pixels vermelhos dispersos de forma granular por toda a matriz territorial. Embora ocorram de maneira pulverizada, esses polígonos críticos mapeiam com precisão cirúrgica os pontos de máxima vulnerabilidade ecológica, causados pela sobreposição da perda recente de vegetação com a proximidade de encostas íngremes ou da rede hidrográfica. Essas zonas de alta criticidade devem ser alvo imediato de políticas públicas de fiscalização remota, cercamento e projetos de restauração florestal ativa, servindo como subsídio direto para a governança ambiental de Três Lagoas.




Figura 10. Zoneamento final de risco ambiental do município de Três Lagoas (MS), classificando o território em áreas adequadas, áreas com restrições ambientais e áreas críticas para conservação, com base no Índice de Risco Ambiental (IRA).

A validação cruzada espacial do modelo ajustado para o ano de 2018 revelou inconsistências importantes quando confrontada diretamente com os dados de referência da Coleção 9 do MapBiomas. Conforme ilustrado na Figura 11, a taxa de concordância espacial entre o classificador Random Forest e a base de referência foi de apenas 46,5% dos pontos válidos testados dentro do limite político-administrativo de Três Lagoas (MS). Esse resultado contrasta com a acurácia global de 90,91% obtida na validação interna do modelo, evidenciando diferenças metodológicas, temporais e espaciais entre as duas abordagens de avaliação.

A distribuição espacial dos vetores de teste indica que, embora os acertos (representados pelos círculos verdes) ocorram de forma dispersa por todo o território municipal, há uma expressiva concentração de discrepâncias cartográficas (quadrados vermelhos) nas porções centro-norte e na franja leste-sudeste do município. Esse padrão de divergência espacial evidencia o desafio analítico de compatibilizar produtos derivados de sensores e metodologias distintas, sugerindo que o mapeamento em escala municipal foi fortemente influenciado por transições graduais e complexas entre as fitofisionomias nativas do Cerrado e as áreas de pastagem cultivada.

Dessa forma, as divergências observadas não necessariamente indicam falhas do modelo de classificação, mas refletem as incertezas inerentes à comparação entre diferentes produtos de mapeamento da cobertura e uso da terra, especialmente em regiões caracterizadas por mosaicos de vegetação e mudanças graduais na paisagem.




Figura 11. Validação dos pontos amostrais utilizados no treinamento e teste do modelo Random Forest por meio da comparação com os dados de uso e cobertura da terra do Projeto MapBiomas. A figura apresenta a correspondência espacial entre as classes atribuídas aos pontos coletados e as classes de referência do MapBiomas, permitindo avaliar a consistência

das amostras utilizadas na classificação da conversão de vegetação nativa para pastagem no município de Três Lagoas (MS).

De forma geral, os resultados demonstram que a integração entre dados MODIS, índices de vegetação, aprendizado de máquina e análise espacial permitiu identificar padrões de conversão da vegetação nativa para pastagem no município de Três Lagoas (MS). O modelo Random Forest apresentou elevado desempenho na classificação do uso do solo, enquanto os produtos derivados, como o Índice de Risco Ambiental e o Zoneamento Ambiental, possibilitaram identificar áreas prioritárias para monitoramento e conservação. Esses resultados fornecem uma base técnica consistente para o planejamento territorial e para a construção de estratégias voltadas ao uso sustentável dos recursos naturais do Cerrado.

A Tabela 1 apresenta uma síntese dos principais resultados obtidos. Observa-se que o modelo Random Forest apresentou elevado desempenho na classificação das classes de uso do solo, possibilitando identificar 12.368,75 ha de conversão de vegetação para pastagem e 12.868,75 ha de áreas em regeneração no período analisado. Esses resultados serviram de base para a construção do Índice de Risco Ambiental e do zoneamento territorial apresentado nas seções seguintes.

Tabela 1. Síntese dos resultados obtidos na análise da conversão de vegetação nativa para pastagem no município de Três Lagoas (MS), Cerrado, entre 2018 e 2024, utilizando dados MODIS e o algoritmo Random Forest.

Categoria	Indicador	Resultado
Área de estudo	Município	Três Lagoas (MS)
Área de estudo	Bioma	Cerrado
Área de estudo	Período analisado	2018–2024
Dados utilizados	Sensor	MODIS MOD13Q1
Dados utilizados	Resolução espacial	250 m
Dados utilizados	Resolução temporal	16 dias
Amostras	Total de pontos válidos	254
Amostras	Vegetação	150
Amostras	Pastagem	104
Random Forest	Número de árvores	200
Random Forest	Acurácia global	90,91%
Random Forest	Coeficiente Kappa	0,81
Random Forest	F1-score	0,90
Random Forest	Validação cruzada (5-fold)	0,9055 ± 0,0261

Categoria	Indicador	Resultado
Mudanças de uso do solo	Conversão vegetação → pastagem	12.368,75 ha
Mudanças de uso do solo	Regeneração da vegetação	12.868,75 ha
Índice de Risco Ambiental (IRA)	Baixo risco	15.762,50 ha
Índice de Risco Ambiental (IRA)	Médio risco	36.787,50 ha
Índice de Risco Ambiental (IRA)	Alto risco	9.950,00 ha
Zoneamento ambiental	Áreas adequadas	15.762,50 ha
Zoneamento ambiental	Áreas com restrições	34.368,75 ha
Zoneamento ambiental	Áreas críticas	12.368,75 ha

Fonte: Elaborado por Carolina da Silva Ezequiel (2026), a partir de dados MODIS MOD13Q1 e processamento em ambiente Python.

Discussão

Os resultados obtidos neste estudo evidenciam uma dinâmica contínua de transformação do uso e cobertura do solo no município de Três Lagoas (MS) entre 2018 e 2024. A conversão de aproximadamente 12.368,75 hectares de vegetação para pastagem confirma a permanência da pressão exercida pelas atividades agropecuárias sobre áreas do Cerrado, um dos biomas brasileiros mais impactados pela expansão do uso antrópico da terra (ALENCAR et al., 2020). Ao mesmo tempo, a identificação de áreas em regeneração demonstra que os processos de recuperação da vegetação também fazem parte da dinâmica territorial observada na região.

Embora a perda de cobertura vegetal observada seja significativa, os resultados também indicaram a regeneração de 12.868,75 hectares, sugerindo que processos de recuperação da vegetação ocorrem simultaneamente à expansão das pastagens. Esse balanço entre conversão e regeneração demonstra a elevada dinâmica espacial do uso do solo na região, caracterizada por ciclos contínuos de ocupação, abandono e recuperação da cobertura vegetal, fenômeno amplamente observado na fronteira agrícola do Centro-Oeste (MAPBIOMAS, 2024).

Entretanto, a simples equivalência entre áreas convertidas e regeneradas não implica necessariamente na manutenção da integridade ecológica do ecossistema. Áreas em regeneração secundária frequentemente apresentam composição florística, estrutura tridimensional e funcionalidade ecológica drasticamente distintas da vegetação nativa original em clímax (VIEIRA et al., 2015).

O elevado desempenho do modelo *Random Forest*, evidenciado pela acurácia global de 90,91%, coeficiente Kappa de 0,81 e F1-score de 0,90, demonstra a eficiência da integração entre dados de sensoriamento remoto e algoritmos de aprendizado de máquina para o monitoramento ambiental. Resultados de alta performance semelhantes têm sido reportados em estudos recentes que empregaram o *Random Forest* para a classificação do uso e cobertura do solo em ambientes tropicais, reforçando a robustez dessa abordagem para aplicações em larga escala (SOUZA et al., 2020).

Apesar da elevada acurácia obtida durante a validação interna do modelo, a comparação com os dados da Coleção 9 do MapBiomias apresentou concordância espacial de 46,5%. Essa diferença evidencia os desafios inerentes à comparação entre produtos cartográficos produzidos por metodologias distintas, resoluções espaciais diferentes e critérios específicos de classificação. Assim, os resultados devem ser interpretados considerando as incertezas associadas à validação externa em estudos de sensoriamento remoto.

A análise da importância das variáveis revelou que o NDVI de 2018 foi o principal preditor da classificação, seguido pelo Δ NDVI. Esse resultado indica que tanto as características estruturais originais da vegetação quanto suas alterações temporais desempenham papel fundamental na identificação de processos de conversão do uso da terra. Tais achados corroboram estudos que apontam os índices de vegetação derivados de sensoriamento remoto como ferramentas eficazes para monitorar alterações fenológicas e detectar processos de degradação da cobertura vegetal (JENSEN, 2011).

A projeção realizada para o ano de 2030 sugere a continuidade da expansão das áreas de pastagem caso as tendências observadas entre 2018 e 2024 sejam mantidas. Embora os cenários produzidos possuam caráter exploratório, eles fornecem informações fundamentais para a governança de terras. A manutenção desse processo pode resultar em maior fragmentação da paisagem, redução da conectividade entre remanescentes vegetais e intensificação da pressão sobre os serviços ecossistêmicos essenciais fornecidos pelo Cerrado, como a regulação climática e a conservação de habitats (IPCC, 2019).

A análise integrada com a rede hidrográfica demonstrou que parte das áreas classificadas com maior risco ambiental encontra-se próxima a corpos hídricos. A remoção da vegetação ripária nessas regiões desprotege o solo, o que favorece processos erosivos, aumenta de forma linear o transporte de sedimentos e compromete a qualidade dos recursos hídricos superficiais (ANA, 2020). Esses resultados reforçam a importância crucial da manutenção da cobertura vegetal em áreas ambientalmente sensíveis, em estrita consonância com a proteção de cursos d'água exigida pela legislação florestal (BRASIL, 2012).

O Índice de Risco Ambiental (IRA) mostrou-se eficiente na integração de diferentes fatores de vulnerabilidade física e de uso, permitindo identificar 9.950 hectares classificados como de alto risco ambiental. Paralelamente, o zoneamento ambiental identificou 12.368,75 hectares considerados críticos para conservação e 34.368,75 hectares com restrições ambientais.

O emprego de abordagens multicritério para essa finalidade espacial encontra amparo na literatura de planejamento territorial (EASTMAN, 2016). Essas informações são estratégicas e podem auxiliar diretamente os gestores públicos na definição de áreas prioritárias para monitoramento coercitivo, fiscalização remota e implementação de políticas locais de conservação e incentivos ecológicos (SANTOS, 2004).

Outro aspecto relevante do trabalho foi a disponibilização dos resultados em uma plataforma interativa de acesso público (Folium/Python). A ferramenta desenvolvida permite a visualização espacial dos mapas de uso do solo, das áreas de conversão, dos níveis de risco ambiental e dos cenários futuros projetados. Dessa forma, o estudo extrapola o campo puramente acadêmico e oferece um produto tecnológico com potencial aplicação prática na

gestão territorial e ambiental municipal, alinhando-se diretamente aos princípios contemporâneos da ciência aberta (REZENDE; REZENDE, 2022).

Limitações

Apesar dos resultados promissores, algumas limitações metodológicas devem ser consideradas para a correta interpretação do modelo. A principal delas está relacionada à resolução espacial dos dados MODIS (250 metros). Embora essa resolução seja perfeitamente adequada para análises regionais e monitoramento macrotemporal de longo prazo (DIDAN, 2021), ela induz ao efeito de pixel misto, o que pode omitir pequenas áreas de conversão linear ou fragmentos inseridos em paisagens altamente heterogêneas. Sensores com resoluções espaciais mais refinadas, como o Sentinel-2 (10 metros), proporcionam um maior detalhamento das franjas de transição e reduzem tais omissões (GORELICK *et al.*, 2017).

Outra limitação refere-se à amostragem para o treinamento do classificador, executada por interpretação visual sobre imagens de tela. Apesar de o procedimento ser amplamente aceito e adotado na ausência de dados históricos de campo (CONGALTON; GREEN, 2019), ele insere subjetividade e potenciais incertezas associadas à experiência do analista frente à complexidade fitofisionômica do Cerrado.

Além disso, os cenários preditivos mapeados para 2030 foram construídos a partir da extrapolação das tendências observadas entre 2018 e 2024 por meio de uma abordagem de progressão linear. Dessa forma, fatores externos que influenciam a dinâmica de uso da terra, como eventos climáticos extremos, alterações econômicas, incentivos governamentais ou mudanças na legislação ambiental, não foram incorporados ao modelo (EASTMAN, 2016).

Como perspectivas futuras, recomenda-se:

- A migração da série temporal para coleções de sensores de maior resolução espacial (como o Sentinel-2 ou Landsat-9);
- A incorporação de dados de inventários de campo para a validação real das classificações;
- A aplicação de algoritmos preditivos que integrem variáveis socioeconômicas (e.g., malhas viárias, distância de silos e PIBs municipais) e climáticas.

Essas melhorias poderão ampliar consideravelmente a precisão dos cenários futuros e consolidar o uso prático do sistema como instrumento de apoio ao planejamento territorial sustentável de Três Lagoas (MS).

Considerações finais

O presente estudo cumpriu com êxito o objetivo de desenvolver um sistema inteligente e automatizado para o monitoramento espaço-temporal da conversão de vegetação nativa em pastagens no município de Três Lagoas (MS). A integração de dados orbitais do sensor MODIS com o algoritmo de aprendizado de máquina *Random Forest* provou ser uma abordagem robusta e altamente escalável para a governança ambiental regional, validada por uma acurácia global de 90,91% e um índice Kappa de 0,81.

Os resultados empíricos revelaram uma paisagem em intensa transformação antrópica entre 2018 e 2024. Embora tenha sido identificada a regeneração de 12.868,75 hectares, a conversão paralela de 12.368,75 hectares de vegetação acende um alerta sobre a

fragmentação contínua do ecossistema do Cerrado. A modelagem preditiva executada para o ano de 2030 indicou que, sob o atual regime socioeconômico de expansão, a pressão sobre as franjas de vegetação remanescente persistirá, ameaçando serviços ecossistêmicos vitais.

A principal contribuição prática desta pesquisa reside na espacialização do Índice de Risco Ambiental (IRA) e na formulação da proposta de zoneamento ecológico. Ao mapear 12.368,75 hectares como críticos para a conservação e apontar áreas de alto risco nas proximidades da rede hidrográfica, o trabalho fornece uma ferramenta promissora para subsidiar o planejamento territorial. Adicionalmente, a disponibilização desses dados por meio de uma interface interativa em Python (Folium) democratiza o acesso à informação geográfica, transferindo o conhecimento gerado na academia diretamente para os gestores públicos e a sociedade civil.

Por fim, conclui-se que o sensoriamento remoto associado à Inteligência Artificial constitui uma ferramenta indispensável para o cumprimento das metas de sustentabilidade municipal. Superadas as limitações de resolução espacial em trabalhos futuros, este sistema inteligente consolida-se como um mecanismo viável de monitoramento contínuo, fundamental para conciliar a produção agropecuária de Três Lagoas com a salvaguarda de seus recursos hídricos e da biodiversidade do Cerrado.

Em síntese, os resultados demonstram que a integração entre sensoriamento remoto, aprendizado de máquina e análise espacial constitui uma abordagem eficiente para o monitoramento ambiental em escala municipal. Além de contribuir para a compreensão das mudanças recentes na cobertura do solo, o sistema desenvolvido oferece subsídios para o planejamento territorial, identificação de áreas prioritárias para conservação e apoio à tomada de decisão, podendo ser adaptado e aplicado em outras regiões do Cerrado e de outros biomas brasileiros.

Referências

- AGÊNCIA NACIONAL DE ÁGUAS E SANEAMENTO BÁSICO (ANA). **Metadados da Rede Hidrográfica Codificada do Brasil**. Brasília: ANA, 2020. Disponível em: www.gov.br. Acesso em: 16 jun. 2026.
- ALENCAR, A. *et al.* **Desmatamento no Cerrado: balanço de três décadas e a importância da vegetação nativa**. Brasília: IPAM, 2020.
- AUSTIN, J. *et al.* **earthaccess**: Search, download and stream NASA Earth Science data with Python. version 0.8.0. Zenodo, 2023. doi: doi.org.
- BRASIL. **Lei nº 12.651, de 25 de maio de 2012**. Dispõe sobre a proteção da vegetação nativa (Código Florestal brasileiro). Diário Oficial da União: Brasília, DF, 28 maio 2012.
- BREIMAN, L. Random Forests. *Machine Learning*, v. 45, n. 1, p. 5-32, 2001.
- CONGALTON, R. G.; GREEN, K. **Assessing the Accuracy of Remotely Sensed Data: principles and practices**. 3. ed. Boca Raton: CRC Press, 2019.
- DIDAN, K. **MOD13Q1 MODIS/Terra Vegetation Indices 16-Day L3 Global 250m SIN Grid V061**. NASA EOSDIS Land Processes DAAC, 2021.
- EASTMAN, J. R. **TerrSet**: TerrSet Manual. Worcester: Clark Labs/Clark University, 2016.

- EVSTATIEV, Boris et al. Identification of pasture degradation using remote sensing data and machine learning: A case study of Obichnik. **Applied Sciences**, v. 14, n. 17, p. 7599, 2024.
- FILHO, A. L. **Web Maps com Python e Folium**: desenvolvimento de aplicações GIS interativas. São Paulo: Novatec, 2021.
- GILLIES, S. et al. Rasterio: geospatial raster I/O for Python. GitHub, 2013. Disponível em: <https://github.com/rasterio/rasterio>
- GORELICK, N. *et al.* Google Earth Engine: Planetary-scale geospatial analysis for everyone. **Remote Sensing of Environment**, v. 202, p. 18-27, 2017.
- HUETE, A. et al. Overview of the radiometric and biophysical performance of the MODIS vegetation indices. **Remote Sensing of Environment**, v. 83, p. 195-213, 2002.
- INPE. PRODES - Monitoramento do desmatamento no bioma Cerrado. São Paulo: INPE, 2024. Disponível em: <http://terrabrasilis.dpi.inpe.br>
- INSTITUTO BRASILEIRO DE GEOGRAFIA E ESTATÍSTICA (IBGE). **Malhas Territoriais**: Municípios brasileiros. Rio de Janeiro: IBGE, 2019. Disponível em: ibge.gov.br. Acesso em: 16 jun. 2026.
- INTERGOVERNMENTAL PANEL ON CLIMATE CHANGE (IPCC). **Climate Change and Land**: an IPCC special report on climate change, desertification, land degradation, sustainable land management, food security, and greenhouse gas fluxes in terrestrial ecosystems. Genebra: IPCC, 2019.
- JENSEN, J. R. **Sensoriamento Remoto da Superfície Terrestre**: uma perspectiva em recursos ambientais. 2. ed. São José dos Campos: Parêntese, 2011.
- JORDAHL, K. et al. GeoPandas: open source project to make working with geospatial data in Python easier. GitHub, 2020.
- JORDANE, E. A. et al. Uso do Random Forest para mapeamento de uso e cobertura do solo no Cerrado. *Revista Brasileira de Cartografia*, 2021.
- MAPBIOMAS. Coleção 10 da Série Anual de Mapas de Cobertura e Uso da Terra do Brasil. 2024. Disponível em: <https://mapbiomas.org>
- MAPBIOMAS. **Coleção 8 da Série Anual de Mapas de Cobertura e Uso da Terra no Brasil**. Projeto de Mapeamento Anual do Uso e Cobertura da Terra no Brasil, 2023. Disponível em: mapbiomas.org. Acesso em: 15 jun. 2026.
- MAPBIOMAS. **Coleção 9 da Série Anual de Mapas de Cobertura e Uso da Terra no Brasil**. Projeto de Mapeamento Anual do Uso e Cobertura da Terra no Brasil, 2024. Disponível em: mapbiomas.org. Acesso em: 16 jun. 2026.
- MATO GROSSO DO SUL. Secretaria de Estado de Meio Ambiente, Desenvolvimento Econômico, Produção e Agricultura Familiar (SEMAGRO). **Plano de Desenvolvimento Sustentável de Mato Grosso do Sul**. Campo Grande: SEMAGRO, 2020.
- MCKINNEY, W. Data Structures for Statistical Computing in Python. Proceedings of the 9th Python in Science Conference, 2010.
- MUXIYE, Muxiye; YONEZAWA, Chinatsu. Multi-temporal and multiscale satellite remote sensing imagery analysis for detecting pasture area changes after grazing cessation due to the fukushima daiichi nuclear disaster. **Remote Sensing**, v. 15, n. 22, p. 5416, 2023.
- NASA. MODIS/Terra Vegetation Indices 16-Day L3 Global 250m SIN Grid V061 (MOD13Q1). NASA EOSDIS LP DAAC, 2024. DOI: 10.5067/MODIS/MOD13Q1.061

- Ogungbuyi, M. G., Mohammed, C., Ara, I., Fischer, A. M., & Harrison, M. T. (2023). Advancing Skyborne Technologies and High-Resolution Satellites for Pasture Monitoring and Improved Management: A Review. *Remote Sensing*. <https://doi.org/10.3390/rs15194866>
- PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825-2830, 2011.
- PYTHON SOFTWARE FOUNDATION. Python Language Reference, version 3.x. Disponível em: <http://www.python.org>
- REZENDE, L. C.; REZENDE, L. C. Ciência Aberta e Dados Abertos de Pesquisa: novos paradigmas para a comunicação científica. **Revista Brasileira de Biblioteconomia e Documentação**, v. 18, p. 1-21, 2022.
- ROUSE, J. W. et al. Monitoring vegetation systems in the Great Plains with ERTS. NASA SP-351, 1974.
- SANO, E. E. et al. Land cover mapping of the tropical savanna region in Brazil. *Environmental Monitoring and Assessment*, v. 166, 2010.
- SANTOS, R. F. **Planejamento Ambiental**: teoria e prática. São Paulo: Oficina de Textos, 2004.
- SOKOLOVA, M.; LAPALME, G. A systematic analysis of performance measures for classification tasks. **Information Processing & Management**, v. 45, n. 4, p. 427-437, 2009. doi: doi.org.
- SOUZA, C. M. *et al.* Reconstructing Three Decades of Land Use and Land Cover Changes in Brazilian Biomes with Landsat Archive and Earth Engine. **Remote Sensing**, v. 12, n. 17, p. 2735, 2020. doi: doi.org.
- VALERIANO, M. M. **Topodata**: guia para utilização de dados geomorfométricos locais. São José dos Campos: INPE, 2008. (INPE-15318-RPQ/818).
- VIEIRA, D. L. M. *et al.* Restaurando o Cerrado e a Caatinga: o conhecimento atual. **Pesquisa Florestal Brasileira**, v. 35, n. 84, p. 493-502, 2015. doi: doi.org.